

K-Nächste-Nachbarn (KNN)

- KNN: einer der einfachsten Algorithmen zur Klassifikation
- Kein Modell das zuvor angepasst bzw. gelernt werden muss (vgl. Regression)
- Datengrundlage sind $n-1$ numerische Variablen und 1 kategoriale Variable (Zielvariable)
- Grundidee:
 - Ausgehend von der neuen Beobachtung
 - Suche k ähnlichsten Nachbarbeobachtungen
 - Entscheide per Mehrheitsentscheid, welche Klasse zugeordnet wird
- Für numerische Zielvariable: Klassifikation mittels Regression (Durchschnittsberechnung der k ähnlichsten Nachbarbeobachtungen)

Parameterwahl k

- Parameterwahl für k essentiell für Performance
- Einfachste Wahl: $k = 1$
→ ähnlichste Beobachtung
- In den meisten Fällen ist eine bessere Leistung zu erzielen, wenn $k > 1$
- Allgemein:
 - k zu niedrig → Überanpassung
 - Höhere Werte von k verringern dieses Risiko
 - Zu hohe Werte von k führen zu starker Glättung
- Ziel: Gleichgewicht zwischen Überanpassung und zu starker Glättung

Welchen Wert finden wir, wenn k der Anzahl an Beobachtungen entspricht?

- Distanzmaße messen Entfernung zweier Beobachtungen
- Im Kontext Klassifikation: Distanzmaß bestimmt, wie ähnlich sich zwei Beobachtungen sind

Welche Distanzmaße kennen Sie?